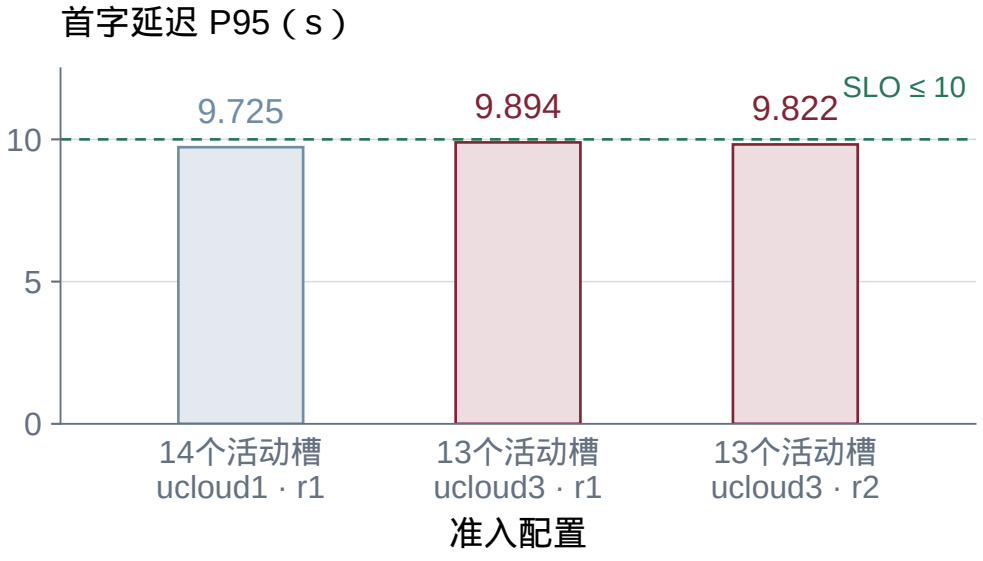
首字延迟 P95（s）
10
5
0
9.725
9.894
9.822
SLO ≤ 10
14个活动槽
ucloud1 · r1
13个活动槽
ucloud3 · r1
13个活动槽
ucloud3 · r2
准入配置

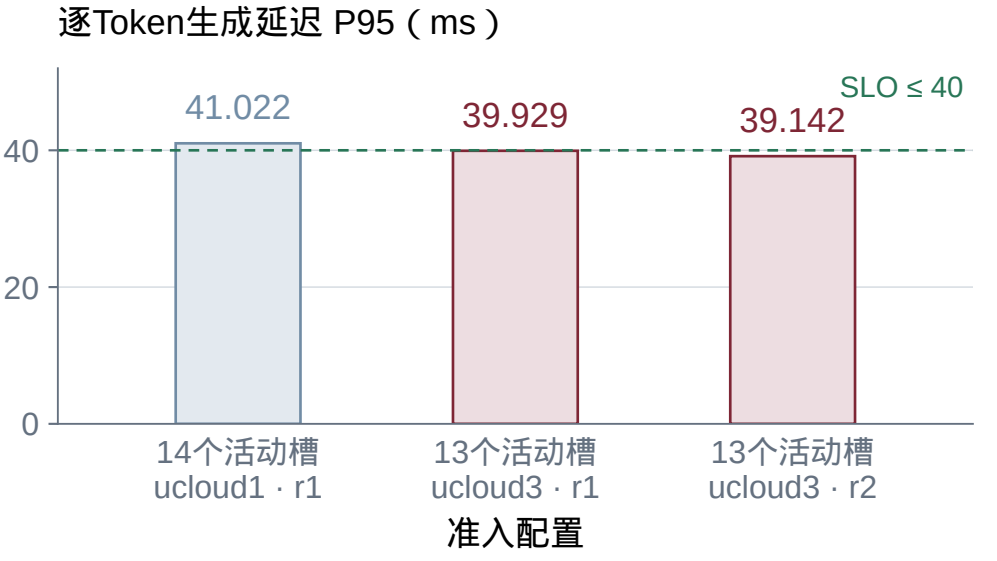
逐Token生成延迟 P95（ms）
40
20
0
41.022
39.929
39.142
SLO ≤ 40
14个活动槽
ucloud1 · r1
13个活动槽
ucloud3 · r1
13个活动槽
ucloud3 · r2
准入配置