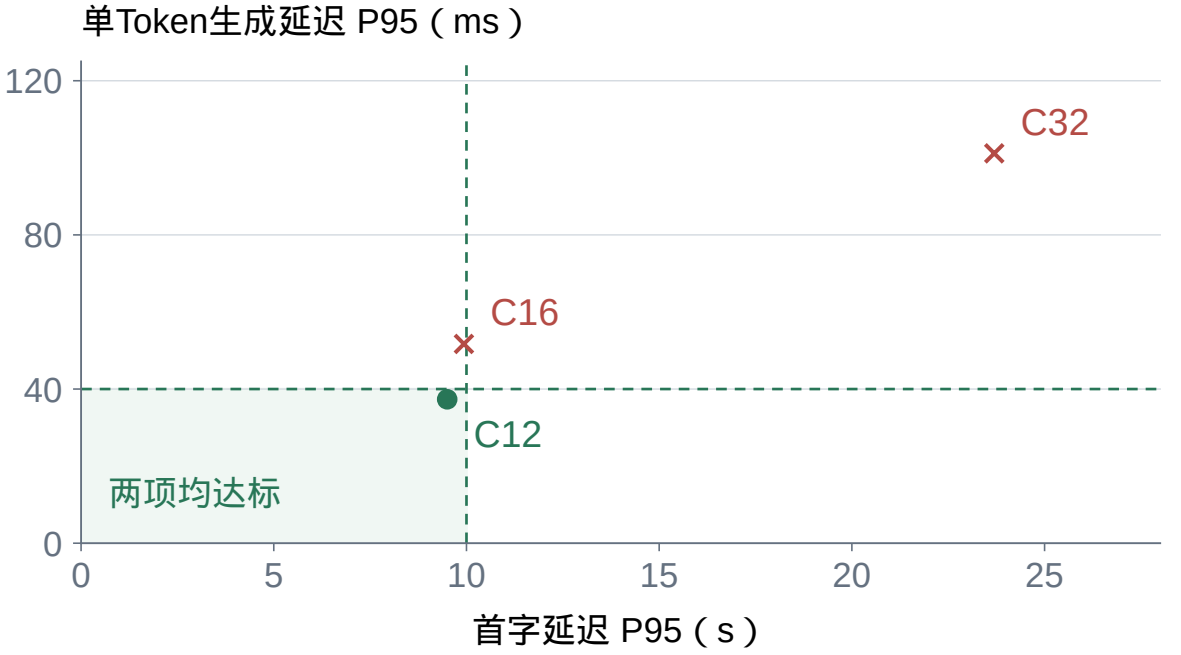
单Token生成延迟 P95（ms）
120
80
40
0
0
5
10
15
20
25
C32
C16
C12
两项均达标
首字延迟 P95（s）