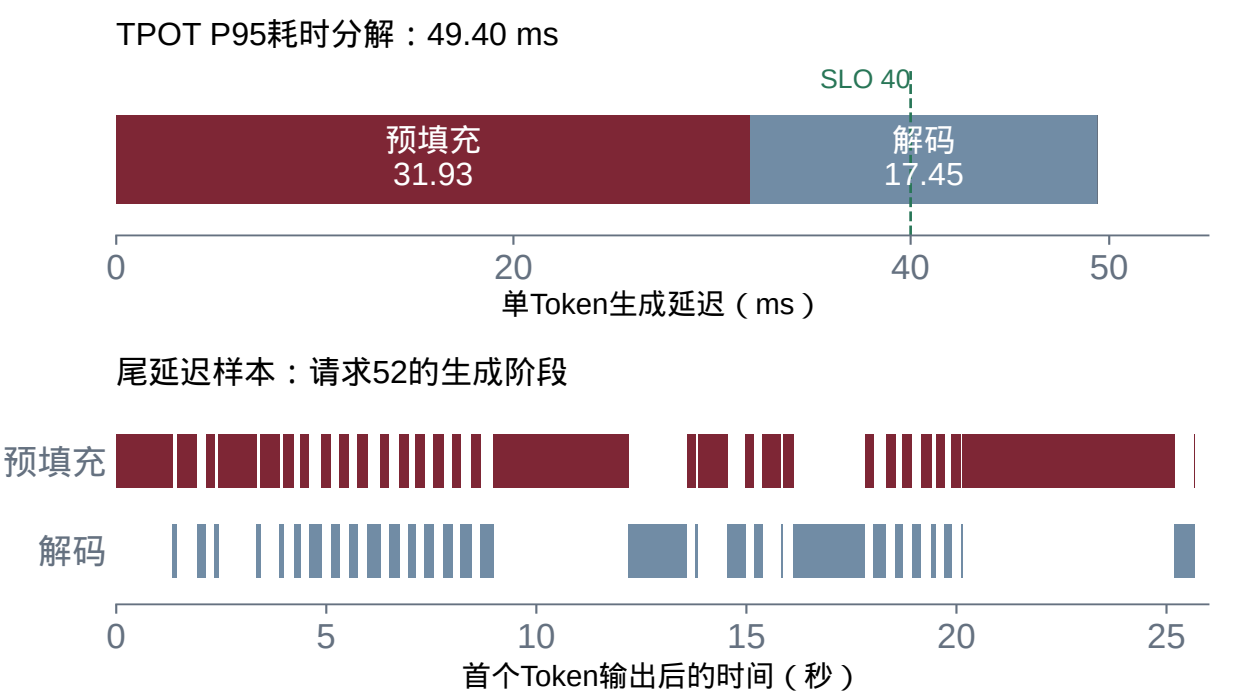
TPOT P95耗时分解：49.40 ms
SLO 40
预填充
31.93
解码
17.45
0
20
40
50
单Token生成延迟（ms）
尾延迟样本：请求52的生成阶段
预填充
解码
0
5
10
15
20
25
首个Token输出后的时间（秒）