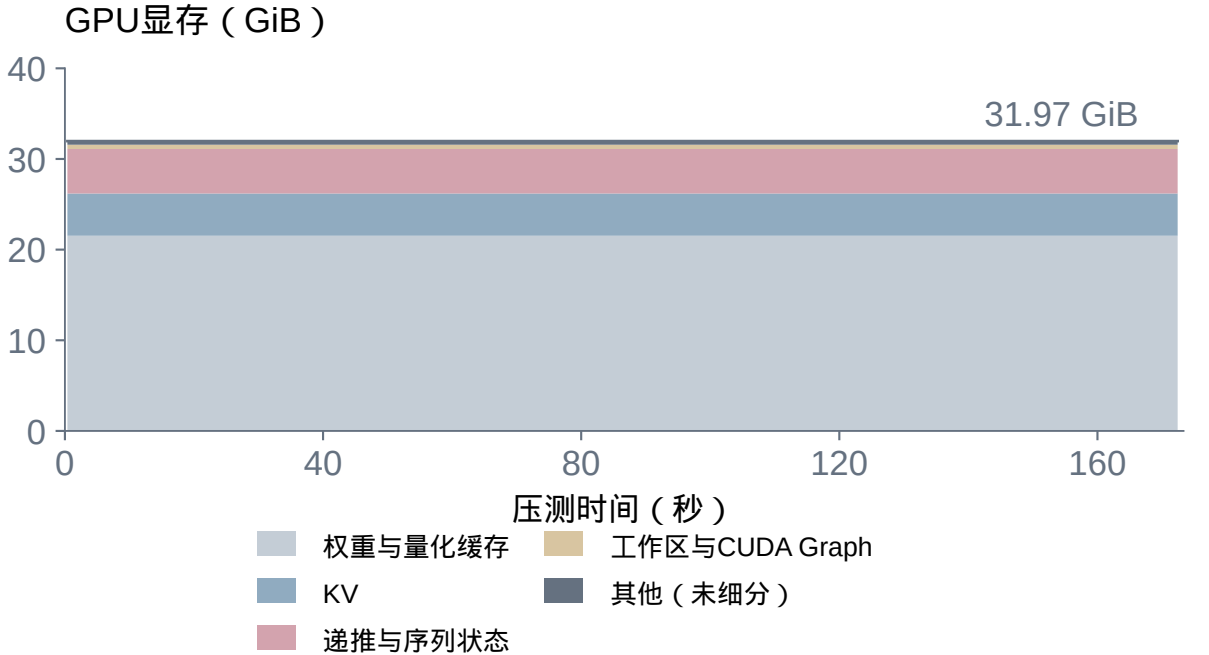
GPU显存（GiB）
40
30
20
10
0
31.97 GiB
0
40
80
120
160
压测时间（秒）
权重与量化缓存
工作区与CUDA Graph
KV
其他（未细分）
递推与序列状态